

Schritt 1: Technisches Setup in RStudio

Für unsere Analyse installieren wir das Paket `readxl`, um Excel-Dateien (.xls und .xlsx) in R einlesen zu können. Dieses Paket enthält die spezialisierte Funktion `read_excel`.

Wichtige Grundlagen zum Paket-Management:

`library()`: Dies ist die Funktion, mit der wir ein bereits installiertes Paket (zum Beispiel `library(readxl)`) in unsere aktuelle R-Sitzung laden. `###` Verfügbarkeit: Erst nachdem der Befehl `library(readxl)` ausgeführt wurde, stehen uns die speziellen Funktionen des Pakets zur Verfügung. `###` Funktion vs. Variable: `read_excel` ist die eigentliche Anweisung, mit der Daten aus einer Excel-Tabelle einer Variablen zugewiesen werden (z. B. `meine_daten <- read_excel(...)`). `###` Base R: Im Gegensatz dazu ist `split()` eine Funktion, die bereits fest in die Programmiersprache R integriert ist und kein extra Laden eines Pakets erfordert (Conversation History).

Um sicherzustellen, dass die in unserem Projekt verwendeten Pakete und deren exakte Versionen gespeichert und für die Zukunft festgehalten werden, installieren wir das Paket `renv` über die Console. Nach die Installation führen wir das Befehl `renv::init()` aus, um es in unserem Projekt integrieren.

```
read_excel("data/Transaktionen_Apriori.xlsx")
```

Schritt 2: Datenimport und Vorbereitung (KDD)

Der erste technische Schritt im KDD-Prozess (Knowledge Discovery in Databases) ist der Import der Daten. Mit der folgenden Funktion laden wir die speziell für diese Aufgabe bereitgestellten Transaktionsdaten.

Laden der Bibliothek

```
library(readxl)
```

Import der Transaktionsdatei

Wir importieren nun die Datei `Transaktionen_Apriori.xlsx` in RStudio. Da unsere Datei in einem Unterordner namens „data“ liegt, nutzen wir einen relativen Pfad. Dabei schreiben wir den Ordnernamen, gefolgt von einem Vorwärts-Schrägstrich (/) und dem Dateinamen in Anführungszeichen.

Wichtiger Hinweis: Wenn wir die Funktion ohne Zuweisung ausführen, wird das Ergebnis nur in der Konsole angezeigt und nicht für spätere Schritte (wie die Gruppierung) gespeichert (Conversation History).

Import der Daten aus dem Unterordner “data”

Hinweis: In einem echten Projekt nutzen wir "<-", um die Daten zu speichern.

```
read_excel("data/Transaktionen_Apriori.xlsx")
```

```
## # A tibble: 32,109 x 19
##   Bestellungsnummer Bestellungsdatum   ProduktKey Auftragsmenge   Umsatz
##   <chr>             <dtm>             <chr>             <dbl>   <dbl>
## 1 41112             2023-02-24 00:00:00 136772             1    428.
## 2 41112             2023-02-24 00:00:00 135888             1     7.99
## 3 41112             2023-02-24 00:00:00 135180             1    14.0
## 4 41112             2023-02-24 00:00:00 135793             1    20.0
## 5 41113             2023-08-28 00:00:00 135792             1  3485.
## 6 41113             2023-08-28 00:00:00 136409             1     9.99
## 7 41113             2023-08-28 00:00:00 135462             1    30.0
## 8 41114             2023-04-08 00:00:00 135599             1  2920.
## 9 41114             2023-04-08 00:00:00 134474             1     9.99
## 10 41114            2023-04-08 00:00:00 134667             1    16.0
## # i 32,099 more rows
## # i 14 more variables: DirektkundeKey <dbl>, LandKey <dbl>, ProduktBuKey <chr>,
## #   Modellreihe <chr>, ProduktName <chr>, Listenpreis <chr>, Farbe <chr>,
## #   Groesse <chr>, Gewicht <chr>, ProduktGruppeKey <dbl>,
## #   ProduktGruppeBuKey <chr>, ProduktGruppeName <chr>,
## #   ProduktKategorieKey <dbl>, ProduktKategorieName <chr>
```